

1 Регрессионный анализ

Предварительные сведения по регрессионному анализу

Имеется n значений независимых переменных X_1, X_2, \dots, X_p и зависимой переменной Y (рисунок 1).

| Y | X_1 | X_2 | ... | X_p |
|-------|----------|----------|-----|----------|
| y_1 | x_{11} | x_{12} | ... | x_{1p} |
| y_2 | x_{21} | x_{22} | ... | x_{2p} |
| ... | ... | ... | ... | ... |
| y_n | x_{n1} | x_{n2} | ... | x_{np} |

Рисунок 1 – Исходных данных для проведения регрессионного анализа

Наиболее часто встречаются следующие регрессионные зависимости:

- 1) линейная $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon$;
- 2) степенная $Y = \beta_0 X_1^{\beta_1} X_2^{\beta_2} \dots X_p^{\beta_p} \varepsilon$;
- 3) экспоненциальная $Y = e^{\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon}$;
- 4) параболическая $Y = \beta_0 + \beta_1 X_1^2 + \beta_2 X_2^2 + \dots + \beta_p X_p^2 + \varepsilon$;
- 5) гиперболическая $Y = \beta_0 + \frac{\beta_1}{X_1} + \frac{\beta_2}{X_2} + \dots + \frac{\beta_p}{X_p} + \varepsilon$.

Пример 1: предположим, что зависимость расходов на продукты питания по совокупности семей характеризуется следующим уравнением:

$$\hat{y} = 0.5 + 0.35x_1 + 0.73x_2,$$

где y – расходы семьи за месяц на продукты питания, тыс. руб.;

x_1 – месячный доход на одного члена семьи, тыс. руб.;

x_2 – размер семьи, человек.

Из уравнения можно сделать вывод о том, что при увеличении только месячного дохода на 1 тыс. руб., расходы на продукты питания в среднем увеличатся на 350 руб., а при увеличении размера семьи на 1 человека расходы возрастут в среднем на 730 рублей.

Пример 2: предположим, что при исследовании спроса на мясо получено уравнение

$$\hat{y} = 0.82 \cdot x_1^{-2.63} x_2^{1.11},$$

где y – количество спрашиваемого мяса; x_1 – цена; x_2 – доход. Здесь коэффициенты β_1 и β_2 – эластичности. Следовательно, рост цен на 1% при том же доходе вызывает снижение спроса в среднем на 2,63%. Увеличение дохода на 1% обусловливает при неизменных ценах рост спроса на 1,11%.

Основное значение имеют линейные модели (относительно параметров регрессии) в силу своей простоты. Нелинейные формы зависимости часто преобразуются к линейным путем линеаризации.

Наилучшие оценки параметров

$\beta_0, \beta_1, \beta_2, \dots, \beta_p$: $b_0, b_1, b_2, \dots, b_p$ определяются методом наименьших квадратов (МНК). Оценки коэффициенты регрессии находятся по критерию:

$$F = \sum_{i=1}^n [y_i - \varphi(x_{i1}, x_{i2}, \dots, x_{ip})]^2 \rightarrow \min, \quad (1)$$

где y_i ($i = 1, 2, \dots, n$) – значения результативного фактора (зависимой переменной) Y в i -м наблюдении; $x_{i1}, x_{i2}, \dots, x_{ip}$ – i -е наблюдения независимых переменных X_1, X_2, \dots, X_p ; n – количество наблюдений.

Реализация этого критерия приводит к системе уравнений

$$\frac{\partial F}{\partial b_j} = 0, \quad j = 0, 1, 2, \dots, p, \quad (2)$$

из которого определяют значения параметров $b_0, b_1, b_2, \dots, b_p$.

Пример проведения регрессионного анализа с помощью R и RStudio

Построение линейной модели множественной регрессии и ее анализ проведем в **R** и **RStudio** для следующих исходных данных.

По условным данным за два года (см. таблица 1) изучается зависимость оборота розничной торговли (Y , млрд. руб.) от ряда факторов: X_1 – денежные доходы населения, млрд. руб.; X_2 – доля доходов, используемых на покупку товаров и оплату услуг, млрд. руб.; X_3 – уровень инфляции за последний год, %; X_4 – официальный курс рубля по отношению к доллару США (данные условные).

Таблица 1 – Исходные данные

| Месяц | Y | X ₁ | X ₂ | X ₃ | X ₄ |
|-------|-------|----------------|----------------|----------------|----------------|
| 1 | 76,4 | 117,7 | 81,6 | 10,3 | 28,5 |
| 2 | 77,6 | 123,8 | 73,2 | 11,4 | 28,7 |
| 3 | 88,2 | 126,9 | 75,3 | 12,2 | 29,1 |
| 4 | 87,3 | 134,1 | 71,3 | 11,5 | 29,2 |
| 5 | 82,5 | 123,1 | 77,3 | 11,2 | 29,1 |
| 6 | 79,4 | 126,7 | 76,1 | 10,5 | 29,2 |
| 7 | 80,3 | 130,4 | 76,6 | 9,4 | 29,3 |
| 8 | 80,1 | 129,3 | 84,7 | 9,5 | 29,2 |
| 9 | 105,2 | 145,4 | 92,4 | 9,3 | 29,1 |
| 10 | 102,5 | 163,8 | 80,3 | 9,2 | 28,7 |
| 11 | 108,7 | 164,8 | 82,6 | 9,4 | 28,4 |
| 12 | 104,5 | 165,3 | 70,9 | 9,7 | 27,8 |
| 13 | 103,7 | 164,1 | 89,9 | 8,2 | 27,7 |
| 14 | 117,8 | 183,7 | 81,3 | 8,4 | 27,6 |
| 15 | 115,8 | 195,8 | 83,7 | 8,2 | 27,5 |
| 16 | 117,8 | 219,4 | 76,1 | 8,1 | 27,5 |
| 17 | 118,4 | 209,8 | 80,4 | 7,8 | 27,4 |
| 18 | 120,4 | 223,3 | 78,1 | 7,2 | 27,5 |
| 19 | 123,8 | 223,6 | 79,8 | 8,2 | 27,6 |
| 20 | 134,9 | 236,6 | 82,1 | 7,5 | 27,7 |
| 21 | 130,5 | 236,6 | 83,2 | 7,4 | 27,8 |
| 22 | 140,7 | 248,6 | 80,8 | 7,3 | 28,7 |
| 23 | 150,4 | 253,4 | 81,8 | 7,4 | 28,3 |
| 24 | 172,7 | 254,3 | 87,5 | 7,5 | 28,1 |

Требуется:

1. Для заданного набора данных построить линейную модель множественной регрессии.
2. Оценить адекватность и значимость построенного уравнения регрессии.

3. Выделить значимые и незначимые факторы в модели.
4. Построить уравнение регрессии со статистически значимыми факторами.
Дать экономическую интерпретацию параметров модели.
5. Определить расчетные значения зависимой переменной Y и построить графики фактических значений зависимой переменной и расчетных. По оси абсцисс откладываются номера наблюдений.
6. Определить оборот розничной торговли для двух вариантов значений независимых переменных:
 - a. Для одного набора значений переменных $X_1=130, X_2=90, X_3=10$
 - b. Для таблицы значений переменных

| X_1 | X_2 | X_3 |
|-------|-------|-------|
| 100 | 200 | 12 |
| 150 | 190 | 9 |
| 120 | 175 | 10 |

7. Оценить гетероскедастичность дисперсии остатков с помощью тестов Гольдфельда–Квандта и Бреуша-Пагана. Найти рабочие стандартные ошибки параметров модели регрессии.
8. Определить наличие автокорреляции остатков с помощью теста Дарбина-Уотсона.

Решение: Выполним задания 1–6.

В R для построения модели линейной регрессии можно воспользоваться функцией `lm()` из библиотеки `stats`, которая по умолчанию подключена в среде RStudio (аргументы функции приведены в таблице 2).

```
model <- lm(formula, data, na.action)
```

Таблица 2 – Аргументы функции lm()

| | |
|----------------|--|
| formula | <p>$y \sim x_1 + x_2 + x_3$</p> <p>Здесь y – это зависимая переменная; x_1, x_2, x_3 – независимые переменные.</p> <p>Если по умолчанию в модель линейной регрессии должны войти все предикторы, можно записать $y \sim$.</p> <p>Знак “+” используется для разделения предикторов, знак “-“ используется для исключения предикторов из модели, если нужно исключить свободный член, то записывают “-1”</p> <p>Кроме знака “+” между переменными можно поставить следующие символы:</p> |
| | <p>:</p> <p>Обозначает взаимодействие между независимыми переменными. Предсказание значений y по значениям x, z и взаимодействия между x и z будет закодировано как $y \sim x + z + x:z$</p> |
| | <p>*</p> <p>Краткое обозначение для всех возможных взаимодействий. Код $y \sim x * z * w$ в полном виде означает</p> $y \sim x + z + w + x:z + x:w + z:w + x:z:w$ |
| | <p>\wedge</p> <p>Обозначает взаимодействия до определенного порядка. Код $y \sim (x + z + w)^\wedge 2$ в полном виде будет записан как</p> $y \sim x + z + w + x:z + x:w + z:w$ |
| | <p>I()</p> <p>Элемент в скобках интерпретируется как арифметическое выражение. Например,</p> $y \sim x + (z + w)^\wedge 2$ <p>означает $y \sim x + z + w + z:w$.</p> <p>Для сравнения $y \sim x + I((z + w)^\wedge 2)$ означает $y \sim x + h$, где h – это новая переменная, полученная при возведении в квадрат суммы z и w</p> |

| | |
|-----------|--|
| function | В формулах можно использовать математические функции. Например, $\log(y) \sim x + z + w$ будет предсказывать значения $\log(y)$ по значениям x , z и w |
| data | Таблица с исходными данными |
| na.action | Действие в случае наличия в данных NA. По умолчанию такие наблюдения игнорируются |

В таблице 3 перечислены функции, которые используются совместно с результатом функции lm()

Таблица 3 – Функции, которые можно использовать с аргументом model<-lm()

| Функция | Действие |
|----------------|---|
| summary() | Показывает детальную информацию о подогнанной модели |
| coefficients() | Перечисляет параметры модели (свободный член и регрессионные коэффициенты) |
| confint() | Вычисляет доверительные интервалы для параметров модели (по умолчанию доверительная вероятность 95%) |
| fitted() | Выводит на экран предсказанные значения, согласно подогнанной модели |
| residuals() | Показывает остатки для подогнанной модели |
| anova() | Создает таблицу ANOVA (дисперсионного анализа) для подогнанной модели или таблицу ANOVA, сравнивающую две или более моделей |
| vcov() | Выводит ковариационную матрицу для параметров модели. По главной диагонали этой матрицы расположены выборочные дисперсии оцененных параметров модели, корни квадратные из которых дают значения стандартных |

| | |
|-----------|--|
| | ошибок для параметров уравнения регрессии. |
| AIC() | Вычисляет информационный критерий Акаике (Akaike's Information Criterion) |
| plot() | Создает диагностические диаграммы для оценки адекватности модели |
| predict() | Использует подогнанную модель для предсказания зависимой переменной для нового набора данных |

Для выполнения **1-го пункта** задания, необходимо сохранить файл с исходной таблицей как .csv файл. Для этого в Excel нужно сохранить файл как .csv (разделитель – запятые). Пусть, например, этот файл сохранен под именем «К ПЗ множ регр .csv» в папке R/examples. Затем в R-studio можно сделать эту папку текущей. Для этого нужно выбрать в меню Session/Set Working Directory команду Choose Directory... и указать путь к папке, в которой будут храниться файлы. Теперь этот файл нужно выбрать. Можно воспользоваться вкладкой Environment, выбрать Import Dataset/From Text (base)....(см. рисунок 1). Это равносильно выполнению команды

```
df <- read.csv2("К ПЗ множ регр.csv")
View(df)
```

Import Dataset

| | | | | | |
|---|---|---|------|------|------|
| Name | df | Input File | | | |
| Encoding | Automatic | Y;X1;X2;X3;X4 76,4;117,7;81,6;10,3;28,5 77,6;123,8;73,2;11,4;28,7 88,2;126,9;75,3;12,2;29,1 87,3;134,1;71,3;11,5;29,2 82,5;123,1;77,3;11,2;29,1 79,4;126,7;76,1;10,5;29,2 80,3;130,4;76,6;9,4;29,3 80,1;129,3;84,7;9,5;29,2 105,2;145,4;92,4;9,3;29,1 102,5;163,8;80,3;9,2;28,7 108,7;164,8;82,6;9,4;28,4 104,5;165,3;70,9;9,7;27,8 103,7;164,1;89,9;8,2;27,7 117,8;183,7;81,3;8,4;27,6 115,8;195,8;83,7;8,2;27,5 117,8;219,4;76,1;8,1;27,5 118,4;209,8;80,4;7,8;27,4 120,4;223,3;78,1;7,2;27,5 | | | |
| Heading | <input checked="" type="radio"/> Yes <input type="radio"/> No | | | | |
| Row names | Automatic | | | | |
| Separator | Semicolon | | | | |
| Decimal | Comma | | | | |
| Quote | Double ("") | | | | |
| Comment | None | | | | |
| na.strings | NA | | | | |
| <input type="checkbox"/> Strings as factors | | | | | |
| Data Frame | | | | | |
| | Y | X1 | X2 | X3 | X4 |
| 1 | 76.4 | 117.7 | 81.6 | 10.3 | 28.5 |
| 2 | 77.6 | 123.8 | 73.2 | 11.4 | 28.7 |
| 3 | 88.2 | 126.9 | 75.3 | 12.2 | 29.1 |
| 4 | 87.3 | 134.1 | 71.3 | 11.5 | 29.2 |
| 5 | 82.5 | 123.1 | 77.3 | 11.2 | 29.1 |
| 6 | 79.4 | 126.7 | 76.1 | 10.5 | 29.2 |
| 7 | 80.3 | 130.4 | 76.6 | 9.4 | 29.3 |
| 8 | 80.1 | 129.3 | 84.7 | 9.5 | 29.2 |
| 9 | 105.2 | 145.4 | 92.4 | 9.3 | 29.1 |
| 10 | 102.5 | 163.8 | 80.3 | 9.2 | 28.7 |
| 11 | 108.7 | 164.8 | 82.6 | 9.4 | 28.4 |
| 12 | 104.5 | 165.3 | 70.9 | 9.7 | 27.8 |
| 13 | 103.7 | 164.1 | 89.9 | 8.2 | 27.7 |
| 14 | 117.8 | 183.7 | 81.3 | 8.4 | 27.6 |
| 15 | 115.8 | 195.8 | 83.7 | 8.2 | 27.5 |
| 16 | 117.8 | 219.4 | 76.1 | 8.1 | 27.5 |
| 17 | 118.4 | 209.8 | 80.4 | 7.8 | 27.4 |

Рисунок 1 – Выбор файла с исходными данными

В RStudio появится вкладка с этой таблицей (рисунок 2).

| | Y | X1 | X2 | X3 | X4 |
|----|-------|-------|------|------|------|
| 1 | 76.4 | 117.7 | 81.6 | 10.3 | 28.5 |
| 2 | 77.6 | 123.8 | 73.2 | 11.4 | 28.7 |
| 3 | 88.2 | 126.9 | 75.3 | 12.2 | 29.1 |
| 4 | 87.3 | 134.1 | 71.3 | 11.5 | 29.2 |
| 5 | 82.5 | 123.1 | 77.3 | 11.2 | 29.1 |
| 6 | 79.4 | 126.7 | 76.1 | 10.5 | 29.2 |
| 7 | 80.3 | 130.4 | 76.6 | 9.4 | 29.3 |
| 8 | 80.1 | 129.3 | 84.7 | 9.5 | 29.2 |
| 9 | 105.2 | 145.4 | 92.4 | 9.3 | 29.1 |
| 10 | 102.5 | 163.8 | 80.3 | 9.2 | 28.7 |
| 11 | 108.7 | 164.8 | 82.6 | 9.4 | 28.4 |
| 12 | 104.5 | 165.3 | 70.9 | 9.7 | 27.8 |
| 13 | 103.7 | 164.1 | 89.9 | 8.2 | 27.7 |
| 14 | 117.8 | 183.7 | 81.3 | 8.4 | 27.6 |
| 15 | 115.8 | 195.8 | 83.7 | 8.2 | 27.5 |
| 16 | 117.8 | 219.4 | 76.1 | 8.1 | 27.5 |
| 17 | 118.4 | 209.8 | 80.4 | 7.8 | 27.4 |

Showing 1 to 10 of 24 entries, 5 total columns

Рисунок 2 – Вид файла с исходными данными в RStudio

Далее вызываем функцию lm() и заполняем ее аргументы, как показано на рисунке 3. Формулу в функции lm() можно было записать как Y~.

```

#Загружаем таблицу
df <- read.csv2("К ПЗ множ регр.csv")
# Показать таблицу
View(df)

#Расчет параметров уравнения регрессии с помощью lm()
model<-lm(data=df, Y~X1+X2+X3+X4)
summary(model)

```

Рисунок 3 – Построение модели множественной регрессии в R-studio

Нажимаем Ctrl+Enter для выполнения кода. Создается список с именем model, в котором содержатся вычисленные коэффициенты и другая информация по построенной модели. С помощью функции summary() можно вывести детальную информацию о подогнанной модели.

Результаты вычислений представлены на рисунке 4.

The screenshot shows the RStudio interface with the console tab selected. The code from Figure 3 has been run, and the resulting output is displayed:

```

4:1 (Top Level) 
Console Terminal × Jobs ×
R 4.1.0 · ~/≈

Call:
lm(formula = Y ~ X1 + X2 + X3 + X4, data = LR1)

Residuals:
    Min      1Q  Median      3Q     Max
-8.495 -3.019 -1.616  1.562 15.571

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -203.55241   82.87974 -2.456  0.02385 *
X1           0.66553    0.06578 10.117 4.36e-09 ***
X2           1.23927    0.33098  3.744  0.00137 **
X3           6.98020    2.52993  2.759  0.01249 *
X4           1.09074    2.84643  0.383  0.70583
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 6.392 on 19 degrees of freedom
Multiple R-squared:  0.9477, Adjusted R-squared:  0.9367
F-statistic: 86.08 on 4 and 19 DF, p-value: 6.693e-12
> |

```

Рисунок 4 – Результаты регрессионного анализа

Поясним полученные результаты на рисунке 4.

В таблице *Residuals* приведены квартили остатков модели (разницы между фактическими значениями переменной Y и рассчитанными с помощью построенной модели значениями \hat{Y}), минимальный остаток равен -

8,495, 25% значений меньше -3,019, 50% меньше -1,616, 75% меньше 1,562, максимальный остаток равен 15,571.

В таблице Coefficients в столбце Estimate приведены значения оцененных параметров модели, по ним можно выписать уравнение множественной регрессии:

$$\hat{Y} = -203,55 + 0,67X_1 + 1,24X_2 + 6,98X_3 + 1,09X_4. \quad (3)$$

В столбце Std.Error указаны стандартные ошибки параметров модели (их среднеквадратические отклонения), в столбце t value – расчетные значения t-критерия Стьюдента для оценки значимости отдельных параметров модели. Последний столбец таблицы содержит для каждого параметра Р-значение: если Р-значение меньше заданного уровня значимости, то нулевая гипотеза $H_0 : b_j = 0$ отклоняется, то есть коэффициент b_j значимо отличается от нуля (с достаточно большой вероятностью).

Для нашего примера, если принять уровень значимости 0,05 (это вероятность того, что ошибочно отвергается нулевая гипотеза о том, что на самом деле коэффициент b_j равен 0), то значимыми оказываются параметры при всех переменных, кроме X_4 . Переменную X_4 следует исключить из модели, так как скорее всего она не влияет на Y .

Multiple R-squared – множественный *R-квадрат* – это *коэффициент детерминации*, который показывает, какая часть (доля) вариации (изменчивости) объясняемой переменной Y обусловлена вариацией объясняющих переменных ($0 \leq R^2 \leq 1$). Чем ближе R^2 к единице, тем лучше уравнение регрессии аппроксимирует эмпирические данные.

В нашем случае $R^2 \approx 0,948$, что свидетельствует о том, что изменения зависимой переменной Y (оборот розничной торговли) в основном (на 94,8%) можно объяснить изменениями включенных в модель объясняющих переменных – X_1, X_2, X_3, X_4 . Такое значение свидетельствует об **адекватности** модели.

Adjasted R-squared – скорректированный коэффициент детерминации.

$$R_{Adj}^2 = 1 - \left(1 - R^2\right) \frac{n-1}{n-p-1},$$

где n – число наблюдений, p – число объясняющих переменных.

Недостатком коэффициента детерминации R^2 является то, что он увеличивается при добавлении новых объясняющих переменных, хотя это и не обязательно означает улучшение качества регрессионной модели. В этом смысле предпочтительнее использовать R_{Adj}^2 . В отличие от R^2 скорректированный коэффициент R_{Adj}^2 может уменьшаться при введении в модель новых объясняющих переменных, не оказывающих существенное влияние на зависимую переменную.

Residual standart error – стандартная ошибка регрессии $S_{ocm} = \sqrt{S_{ocm}^2}$,

где $S_{ocm}^2 = \sum_{i=1}^n \frac{e_i^2}{n-p-1} = \sum_{i=1}^n \frac{(y_i - \hat{y}_i)^2}{n-p-1}$ – необъясненная дисперсия (мера разброса значений зависимой переменной вокруг линии регрессии), p – число независимых переменных (в нашем случае 4), n – объем выборки (в нашем случае 24).


F-statistic – вычисленное значение критерия Фишера (F-статистики); С помощью него проверяется гипотеза о том, что одновременно все коэффициенты при независимых переменных равны 0 (говорят, что построенное уравнение регрессии не значимо). Уравнение регрессии считается значимым на уровне значимости α , если F больше табличного значения F-критерия, или если величина p-value меньше принятого уровня значимости α , например 0,05.

В нашем примере расчетное значение F- критерия Фишера равно 86,08. Значимость $F = 6,693E-12 = 6,693 \cdot 10^{-12}$, что намного меньше 0,05. Таким образом, полученное уравнение в целом значимо.

Как было сказано ранее из уравнения регрессии следует исключить переменную X_4 . Исключим несущественный фактор X_4 (официальный курс рубля по отношению к доллару США) и построим уравнение зависимости

$$Y=f(X_1, X_2, X_3).$$

Получим модель на рисунке 5. Объект, в котором будет храниться результат моделирования, назовем model_1.



```

Console Terminal × Jobs ×
R 4.1.0 · ~/Documents
> summary(model_1)

Call:
lm(formula = Y ~ X1 + X2 + X3, data = LR1)

Residuals:
    Min      1Q  Median      3Q     Max 
-8.486 -3.132 -1.657  2.109 15.749 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) -178.4539   49.6900 -3.591 0.001825 **  
X1            0.6644    0.0643 10.333 1.82e-09 ***  
X2            1.2721    0.3128  4.067 0.000602 ***  
X3            7.3519    2.2862  3.216 0.004336 **  
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 6.254 on 20 degrees of freedom
Multiple R-squared:  0.9473, Adjusted R-squared:  0.9394 
F-statistic: 119.8 on 3 and 20 DF,  p-value: 5.966e-13

> 

```

Рисунок 5 – Результаты регрессионного анализа со статистически значимыми коэффициентами

Модель зависимости оборота розничной торговли запишется в следующем виде:

$$\hat{Y} = -178,45 + 0,66X_1 + 1,27X_2 + 7,35X_3. \quad (4)$$

Оценим адекватность и значимость уравнения (4) по сравнению с уравнением (3).

Из таблицы (рисунок 5) видно, что значение коэффициента детерминации (R^2) осталось примерно на прежнем уровне, немного возросло значение скорректированного коэффициента детерминации (нормированный R^2), следовательно, можно сделать вывод об адекватности модели.

Стандартная ошибка регрессии для второго уравнения меньше, чем для первого ($6,254 < 6,392$). Расчетное значение F-критерия Фишера увеличилось

примерно на 33. Значимость $F=5,966E-13$, что меньше 0,05, таким образом, полученное уравнение в целом значимо. Также можно сделать вывод о том, что все включенные в модель факторы являются значимыми, так как их P -значение $< 0,05$.

Экономическая интерпретация параметров модели.

Коэффициент $b_1 = 0,66$, означает, что при увеличении только денежных доходов населения (X_1) на 1 тыс. руб. оборот розничной торговли возрастет в среднем на 0,66 тыс. руб., а то что коэффициент $b_2 = 1,27$, означает, что увеличение только доли доходов, используемых на покупку товаров и оплату услуг на 1 тыс. руб., оборот розничной торговли возрастет в среднем на 1,27 тыс. руб. при условии неизменности других двух факторов, коэффициент $b_3 = 7,35$, означает, что при увеличении только уровня инфляции на 1%, оборот розничной торговли возрастет в среднем на 7,35 млрд. руб. при условии неизменности других двух факторов.

С помощью элемента списка `model_1: fitted.values` определим расчетные значения зависимой переменной Y : \hat{Y} и добавим с помощью `cbind()` столбец со значениями \hat{Y} к таблице `df`. При этом `fitted` – это имя столбца. Код на рисунке 6.

```
# Добавление в таблицу df столбца fitted с расчетными значениями Y
df<-cbind(df,fitted=model_1$fitted.values)
```

Рисунок 6

Далее построим график фактических и расчетных значений Y и \hat{Y} :

```
#Построение графиков фактических и расчетных значений Y
plot(1:24, df$Y, type="l", xlab="Номер наблюдения", ylab="Y")
lines(1:24,df$fitted, type="l", col=2)

#Добавление легенды
legend("bottomright", legend = c("Y", "fitted Y"), lwd=1, col = c(2, 1))
```

Рисунок 7




Рисунок 8

Или можно построить график по слоям с помощью пакета `ggplot2` (см. рисунок 9)

```

26 # Построение графиков с помощью пакета ggplot2
27 library(ggplot2)
28 ggplot(NULL, aes(x,y))+geom_line(data=data.frame(x=1:24,y=df$fitted),
29                                     aes(color='расчетные значения Y'))+
30   geom_line(data=data.frame(x=1:24, y=df$Y),
31             aes(color="фактические значения Y"))+
32   labs(x = "Номер наблюдения", y = "Оборот розничной торговли")
33

```

Рисунок 9




Рисунок 10

Для выполнения задания 6 воспользуемся функцией predict(), ее синтаксис

predict(object, newdata, type="response", interval),

где **object** – результат выполнения функции lm();

newdata – дата фрейм со значениями независимых переменных для прогноза;

type – тип прогноза;

interval – тип расчета интервала.

Для варианта задания набора значений переменных $X_1=130$, $X_2=90$, $X_3=10$, создадим дата фрейм

```
dp<-data.frame(X1=130, X2=90, X3=10)
```

и присвоим его аргументу newdata

```
predict(object=model_1, newdata=dp)
```

В результате $Y=95.927$ млрд.руб.

Для таблицы значений переменных

| X_1 | X_2 | X_3 |
|-------|-------|-------|
| 100 | 200 | 12 |
| 150 | 190 | 9 |
| 120 | 175 | 10 |

переменной dp присвоим дата фрейм вида (с помощью c() задают векторы)

```
dp<-data.frame(X1=c(100, 150, 120), X2=c(200, 190, 175), X3=c(12, 9, 10))
```

и присвоим его аргументу newdata

```
predict(object=model_1, newdata=dp)
```

В результате получим

```
> predict(model_1, newdata=dp)
   1      2      3
230.6316 229.0744 197.4128
```

Для выполнения заданий 7–8, потребуется дать следующие пояснения.

Регрессионный анализ включает не только построение самой регрессионной модели, но и исследование остатков $\varepsilon = Y - \hat{Y}$. При этом сами остатки ε_i следует рассматривать как случайные величины.

Каждый оцененный коэффициент регрессии является случайной величиной, свойства которой зависят от свойств остаточного члена ε в регрессионной модели.

Для того чтобы регрессионный анализ, основанный на методе наименьших квадратов, давал наилучшие и обоснованные результаты, необходимо выполнение некоторых предположений относительно поведения остатков ε_i .

Для регрессионных моделей, линейных относительно независимых переменных X_1, X_2, \dots, X_p , должны удовлетворяться **четыре условия Гаусса-Маркова:**

- 1) Матрица X – детерминированная матрица, имеющая максимальный ранг, равный $p+1$.
- 2) Математические ожидания возмущения ε_i ($i = 1, 2, \dots, n$) равны нулю:

$$M(\varepsilon_i) = 0$$

или в матричном виде

$$M(\varepsilon) = 0_n \text{ – нулевая матрица-столбец}$$

- 3) Дисперсия возмущения ε_i постоянна для любого i (условие гомоскедастичности):

$$D(\varepsilon_i) = \sigma_\varepsilon^2$$

Свойство гомоскедастичности на практике проверяется на самом деле для остатков модели, а не для истинных ошибок и может выполняться лишь приближенно. Если условие гомоскедастичности не выполнено (то есть дисперсия ошибок не постоянна), то говорят, что имеет место **условие гетероскедастичности**.

Свойство гомоскедастичности и гетероскедастичности можно проиллюстрировать рисунками:




Рисунок 11. Гомоскедастичность остатков




Рисунок 12. Гетероскедастичность остатков

4) Возмущения ε_i и ε_j не коррелированы (отсутствие автокорреляции остатков):

$$\text{cov}(\varepsilon_i, \varepsilon_j) = 0 \quad (i \neq j).$$

Если все эти условия выполняются, то полученные с помощью МНК оценки коэффициентов регрессии будут обладать свойствами хороших

статистических оценок: несмещенностю¹, состоятельностью² и эффективностью³.

Нарушение 3-го условия – гомоскедастичности остатков приводит к следующим последствиям:

1. МНК-оценки коэффициентов останутся **несмещенными**.
2. МНК-оценки коэффициентов больше **не являются эффективными**.
3. **Стандартные ошибки оценок** коэффициентов, рассчитанные по формуле для случая гомоскедастичности, оказываются **смещенными и несостоительными**. Следовательно, их использование для **тестирования гипотез и построения доверительных интервалов** может привести к **некорректным выводам**.

Первые два перечисленных последствия говорят о том, что МНК-оценки коэффициентов в условиях гетероскедастичности хотя и теряют в точности, однако остаются в среднем правильными. Третье же последствие весьма критично, так как увеличивает вероятность неверной интерпретации результатов моделирования.

Для преодоления 3-го последствия можно посчитать стандартные ошибки МНК-коэффициентов уравнения регрессии по скорректированным формулам, в этом случае, стандартные ошибки станут состоятельными (их называют **робастными стандартными ошибками**). Для этого можно воспользоваться пакетом **sandwich** и функцией **vcovHC()**, с помощью которой можно найти робастные стандартные ошибки для параметров модели регрессии **model**. Аргумент **type** функции **vcovHC()** может принимать значения от **HC0** до **HC5**, и отвечает за способ оценки

¹ Статистическая оценка некоторого параметра называется **несмещенной**, если ее математическое ожидание равно истинному значению этого параметра.

² Свойство **состоительности** оценок заключается в том, что при неограниченном возрастании объема выборки, значение оценки должно стремиться (по вероятности) к истинному значению параметра, а дисперсии оценок должны уменьшаться и в пределе стремиться к нулю.

³ Оценка называется **эффективной**, если она имеет минимальную дисперсию по сравнению с другими оценками заданного класса.

ковариационной матрицы параметров модели регрессии. Корни квадратные из **диагональных элементов матрицы**, полученной с помощью **`vcovHC()`** и есть робастные стандартные ошибки соответствующих коэффициентов модели, начиная с b_0 .

Можно выполнить проверку значимости коэффициентов модели на основе робастных стандартных ошибок с помощью функции **`coeftest()`** (для этого надо загрузить библиотеку **`lmtest`**)

Код приведен ниже:

```
install.packages("sandwich")
library("sandwich")
install.packages("lmtest")
library("lmtest")

#Проверка значимости коэффициентов уравнения на основании
#робастных стандартных ошибок коэффициентов (функция из пакета lmtest)
coeftest(model_1, vcov = vcovHC(model_1,type="HC3"))

# Скорректированная ковариационная матрица коэффициентов модели
vcovHC(model_1, type="HC3")

#Корни квадратные из диагональных элементов скорректированной
ковариационной матрицы
# (робастные стандартные ошибки)
v<-diag(vcovHC(model_1, type="HC3"))^0.5
```

Так же можно выполнить тесты на наличие гетероскедастичности, например, с помощью теста Гольдфельда-Квандта или Бреуша-Пагана.

```
# Тест Гольдфельда-Квандта на гомоскедастичность
install.packages("lmtest")
library ("lmtest")
gqttest(model_1, order.by=~X3, data=df, fraction=8)

#Тест Бреуша-Пагана
```

```
bptest(model_1)
```

Результаты теста Гольфельда-Квандта:

```
Goldfeld-Quandt test

data: model_1
GQ = 0.079181, df1 = 4, df2 = 4, p-value = 0.9846
alternative hypothesis: variance increases from segment 1 to 2
```

Вывод: наблюдается гомоскедастичность относительно переменной X_3 .

Результат применения теста Бреуша-Пагана:

```
studentized Breusch-Pagan test

data: model_1
BP = 3.6928, df = 3, p-value = 0.2966
```

Так как $p\text{-value} > 0.05$, то принимаем нулевую гипотезу об отсутствии гетероскедастичности.

Нарушение 4-го условия – отсутствия автокорреляции остатков

Те же последствия, что и при нарушении 3-го условия.

Для выявления наличия автокорреляции остатков воспользуемся тестом Дарбина-Уотсона – это функция dwtest() из пакета lmtest

```
#Тест Дарбина-Уотсона на автокорреляцию остатков
dwtest (model_1)
```

Этот тест используется для обнаружения автокорреляции первого порядка, т.е. проверяется некоррелированность не любых, а только соседних величин ε_i . Соседними обычно считаются соседние во времени (при рассмотрении временных рядов) или по возрастанию объясняющей переменной X значения ε_i .

$$\varepsilon_i = \rho \cdot \varepsilon_{i-1} + v_i.$$

Гипотеза $H_0 : \rho = 0$ (автокорреляция отсутствует).

Результат

```
data: model_1
DW = 1.3522, p-value = 0.01929
alternative hypothesis: true autocorrelation is greater than 0
```

Так как $p\text{-value} < 0.05$, то гипотезу о том, что коэффициент корреляции равен нулю следует отвергнуть. То есть наблюдается автокорреляция остатков 1-го порядка.