

Выполнил: Тимошинов Егор Борисович

Группа: 16

Лабораторная работа

Регрессионный анализ с помощью R

Цель работы

Изучение методов построения моделей множественной линейной регрессии и оценки их качества на основе статистических данных.

Теоретические сведения

Множественная линейная регрессия используется для моделирования зависимости одной зависимой переменной от нескольких независимых переменных. Модель позволяет оценить влияние каждого предиктора на зависимую переменную с учетом влияния других переменных.

Модель множественной линейной регрессии имеет вид:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \varepsilon$$

где Y — зависимая переменная, X_1, X_2, X_3, X_4 — независимые переменные (предикторы), β_0 — свободный член, $\beta_1, \beta_2, \beta_3, \beta_4$ — коэффициенты регрессии, ε — случайная ошибка.

Задание

1. Загрузить данные и провести их описательный анализ.
2. Построить модель множественной линейной регрессии.
3. Оценить значимость коэффициентов регрессии.
4. Оценить качество модели с помощью коэффициента детерминации и F-статистики.
5. Проанализировать остатки модели.
6. Построить графики для визуализации результатов.

Результаты выполнения задания

Исходные данные

Для анализа использованы данные о 24 наблюдениях. Зависимая переменная — Y , независимые переменные — X_1, X_2, X_3, X_4 .

Описательная статистика по данным:

- Среднее значение Y : 109.15
- Минимальное значение Y : 76.4
- Максимальное значение Y : 172.7

- Среднее значение X_1 : 179.19
- Среднее значение X_2 : 80.29
- Среднее значение X_3 : 9.03
- Среднее значение X_4 : 28.32

Первые 20 наблюдений:

№	Y	X1	X2	X3	X4
1	76.4	117.7	81.6	10.3	28.5
2	77.6	123.8	73.2	11.4	28.7
3	88.2	126.9	75.3	12.2	29.1
4	87.3	134.1	71.3	11.5	29.2
5	82.5	123.1	77.3	11.2	29.1
6	79.4	126.7	76.1	10.5	29.2
7	80.3	130.4	76.6	9.4	29.3
8	80.1	129.3	84.7	9.5	29.2
9	105.2	145.4	92.4	9.3	29.1
10	102.5	163.8	80.3	9.2	28.7
11	108.7	164.8	82.6	9.4	28.4
12	104.5	165.3	70.9	9.7	27.8
13	103.7	164.1	89.9	8.2	27.7
14	117.8	183.7	81.3	8.4	27.6
15	115.8	195.8	83.7	8.2	27.5
16	117.8	219.4	76.1	8.1	27.5
17	118.4	209.8	80.4	7.8	27.4
18	120.4	223.3	78.1	7.2	27.5
19	123.8	223.6	79.8	8.2	27.6
20	134.9	236.6	82.1	7.5	27.7

Результаты моделирования

Коэффициенты модели множественной линейной регрессии:

Коэффициент	Значение	t-статистика	p-value
β_0 (Intercept)	-203.552414	-2.760303	0.012454
β_1 (X_1)	0.665526	11.370809	0.000000
β_2 (X_2)	1.239273	4.208240	0.000476
β_3 (X_3)	6.980195	3.100901	0.005883
β_4 (X_4)	1.090743	0.430677	0.671550

Уравнение модели:

$$Y = -203.552414 + 0.665526 \cdot X_1 + 1.239273 \cdot X_2 + 6.980195 \cdot X_3 + 1.090743 \cdot X_4$$

Оценка качества модели

Метрики качества модели:

- Коэффициент детерминации (R^2): 0.947704
- Скорректированный R^2 : 0.936694
- Среднеквадратическая ошибка (MSE): 32.341483
- Корень из среднеквадратической ошибки (RMSE): 5.686957
- F-статистика: 86.078326
- p-value (F): 0.000000

Коэффициент детерминации $R^2 = 0.947704$ показывает, что модель объясняет 94.77% вариации зависимой переменной. F-статистика = 86.078326 с p-value = 0.000000 указывает на статистическую значимость модели.

График фактических vs предсказанных значений




Рисунок 1. Сравнение фактических и предсказанных значений

На графике показано сравнение фактических значений зависимой переменной Y с предсказанными значениями модели. Точки, близкие к диагональной линии, указывают на хорошее качество модели.

График остатков vs предсказанные значения




Рисунок 2. Зависимость остатков от предсказанных значений

График остатков позволяет проверить предположение о гомоскедастичности (постоянстве дисперсии ошибок). Остатки должны быть случайно распределены вокруг нуля без видимых закономерностей.

Q-Q график остатков




Рисунок 3. Q-Q график остатков для проверки нормальности распределения

Q-Q график используется для проверки нормальности распределения остатков. Если остатки нормально распределены, точки должны лежать близко к прямой линии.

Зависимость Y от предикторов




Рисунок 4. Зависимость зависимой переменной Y от каждого предиктора

На графиках показана зависимость Y от каждого из предикторов X_1, X_2, X_3, X_4 . Линия тренда показывает общую направленность связи между переменными.

Выводы

В ходе выполнения лабораторной работы была построена модель множественной линейной регрессии для анализа зависимости переменной Y от предикторов X_1, X_2, X_3, X_4 . Модель показала хорошее качество с коэффициентом детерминации $R^2 = 0.947704$, что означает, что модель объясняет 94.77% вариации зависимой переменной. F-статистика подтверждает статистическую значимость модели. Анализ остатков не выявил серьезных нарушений предположений регрессионного анализа.